PM2.5 légszennyezés előrejelzés

Tartalom

PM2.5 légszennyezés előrejelzés 1
Bevezetés 2
Cél 2
Hogyan 2
Domain áttekintés 3
Adatok 3
Adatgyűjtés és adatelőkészítés 3
Adatok bemutatása 3
Feature engineering 4
Training 5
Optimalizálás 5
Tesztek, validációk 6
Kiértékelés 7
Összegzés 9
Limitációk 9
Teszt Pipeline 9
Api 10
Tovább fejlesztési lehetőségek 11
AI eszközök használata 12
Felhasznált eszközök 12
Fogalomtár (rövid magyarázatokkal) 13

Bevezetés

A projekt célja a PM2.5 légszennyezettségi értékek rövid távú előrejelzése Győr több mérőállomásán.

Cél

- A környezeti tudatosság és a döntéshozatal támogatása
- Egy olyan modell létrehozása, amely rövid távon (1–12 óra) megbízható előrejelzést ad. (MAE < 5 µg/m³)

A feladat idősoros regressziós probléma, ahol a múltbeli légszennyezési és időjárási adatok alapján kell a következő időlépések értékeit becsülni.

A probléma sajátosságai:

- erős idősoros jelleg (autokorreláció)
- időjárás jelentős hatása
- állomások közti különbségek
- szezonális mintázatok

Korlát:

- az időjárási adat minden állomásra azonos

Hogyan

A probléma megoldása egy end-to-end gépi tanulási pipeline segítségével történik.

A rendszer fő lépései:

- adatgyűjtés publikus API-kból (légszennyezés és időjárás)
- adatok tisztítása és egységesítése
- feature engineering (idősoros, időbeli és domain alapú változók)
- több modell tanítása és összehasonlítása
- modell kiválasztása és optimalizálása
- előrejelzés készítése recursive módszerrel
- időalapú validáció (walk-forward)
- REST API-n keresztüli kiszolgálás

A cél nem csak egy modell létrehozása, hanem egy reprodukálható, moduláris rendszer kialakítása.

Domain áttekintés

A légszennyezés előrejelzése fontos egészségügyi és környezetvédelmi szempontból, mivel a magas PM2.5 koncentráció komoly kockázatot jelent.

A PM2.5 szennyezés két fő módon keletkezhet: közvetlen kibocsátásból (primer részecskék) vagy légköri kémiai folyamatokból (szekunder részecskék).

A legfontosabb primer források:

- közlekedési kibocsátások
- lakossági fűtés (különösen szilárd tüzelőanyagok)
- ipari tevékenység
- építkezések és útfelverődés

A meteorológiai körülmények jelentősen befolyásolják a levegőben lévő szennyezőanyagok koncentrációját. Legfontosabb tényezők:

- szélsebesség
- páratartalom
- hőmérséklet
- csapadék

(Részletesebb leírás:/docs/domain.md)

Adatok

Adatgyűjtés és adatelőkészítés

A rendszer API alapú adatgyűjtést alkalmaz:

- légszennyezési adatok lekérése (OpenAQ)
- időjárási adatok lekérése (Open-Meteo)

Adatok bemutatása

Két adatforrást használunk:

- légszennyezési adatok (PM2.5, NO2, PM10, SO2)
- időjárási adatok (hőmérséklet, páratartalom, szélsebesség, csapadék)

Fő kihívások:

- hiányzó értékek
- mérési zaj
- nem egyenletes időmintavételezés

Adatelőkészítés lépései:

- Adatok betöltése és datetime egységesítése
- Pollution és weather adatok összekapcsolása
- Negatív értékek kezelése (NaN)
- Resampling 1 órás frekvenciára
- Hiányzó értékek interpolálása

- Target létrehozása:
    - pm25_next = következő időlépés

Az idősorokat állomásonként külön kezeljük.

Feature engineering

Idősoros feature-ök

- lag-ek (1, 3, 6, 24 óra)
- rolling statisztikák
    - utolsó 6, 24 óra átlaga
- trend és szórás (3 és 12 óra)

Ezek adják a modell fő prediktív erejét

Idő alapú feature-ök

- ciklikus napszak (sin/cos)
- ciklikus hónap
- hétvége jelző
- fűtési szezon

Időjárási feature-ök

- változások (3 órán belül)
- stagnation index
- mixing index
- ventilation index

Térbeli feature-ök

- location azonosító
- koordináták normalizálása

Dimenziócsökkentés és klaszterezés

PCA és KMeans elemzést végeztünk:

- PCA → magas korreláció a lag feature-ök között
- KMeans → nincs jól elkülönülő klaszterstruktúra

Következtetés:

- fa-alapú modellek miatt nem szükséges dimenziócsökkentés
- a nyers feature-ök használata jobb interpretálhatóságot biztosít

A feature engineering kulcsszerepet játszik a modell teljesítményében, különösen az autoregresszív (lag alapú) változók révén.

Training

A választott modellek főként fa-alapú algoritmusok, mivel jól kezelik a nemlineáris kapcsolatokat és nem érzékenyek a feature-ök közötti korrelációra.

Használt modellek:

- RandomForest
- HistGradientBoosting
- LightGBM
- XGBoost
- Ridge (baseline)

A target logaritmikus transzformációval kerül tanításra:

- log1p → stabilabb tanulás
- expm1 → visszaalakítás

Mentett artifactok:

- modell
- feature lista
- location mapping
- preprocessing paraméterek

A teljes pipeline scriptből futtatható.

Optimalizálás

A modellek hiperparaméter tuningja Optuna segítségével történt.

Az optimalizáció célja:

- a generalizáció javítása
- overfitting csökkentése
- modell stabilitás növelése

Az optimalizáció során:

- több modell (pl. LightGBM, HistGradientBoosting) paraméterei kerültek hangolásra
- idősoros validáció (TimeSeriesSplit) került alkalmazásra

Ez csökkenti annak kockázatát, hogy a modell jövőbeli információt használjon.

Tesztek, validációk

A modell validációja több szinten történt. A módszerek célja az adatszivárgás (data leakage) elkerülése, ami idősoros problémák esetén különösen kritikus.

1. Train/test split

- időalapú szeparáció
- biztosítja a valós előrejelzési helyzet szimulációját

2. Walk-forward validáció

- lépésenkénti előrejelzés
- a modell saját predikcióit használja bemenetként
- horizon alapú kiértékelés

3. Baseline összehasonlítás

- pm25_lag1 (naiv modell)
- segít a modell valódi hozzáadott értékének mérésében

4. Pipeline tesztelés

- script alapú futtatás
- API endpoint validáció

Ez a megközelítés biztosítja a modell robusztus és valós környezetben is működő teljesítményét.

Walkforward validáció

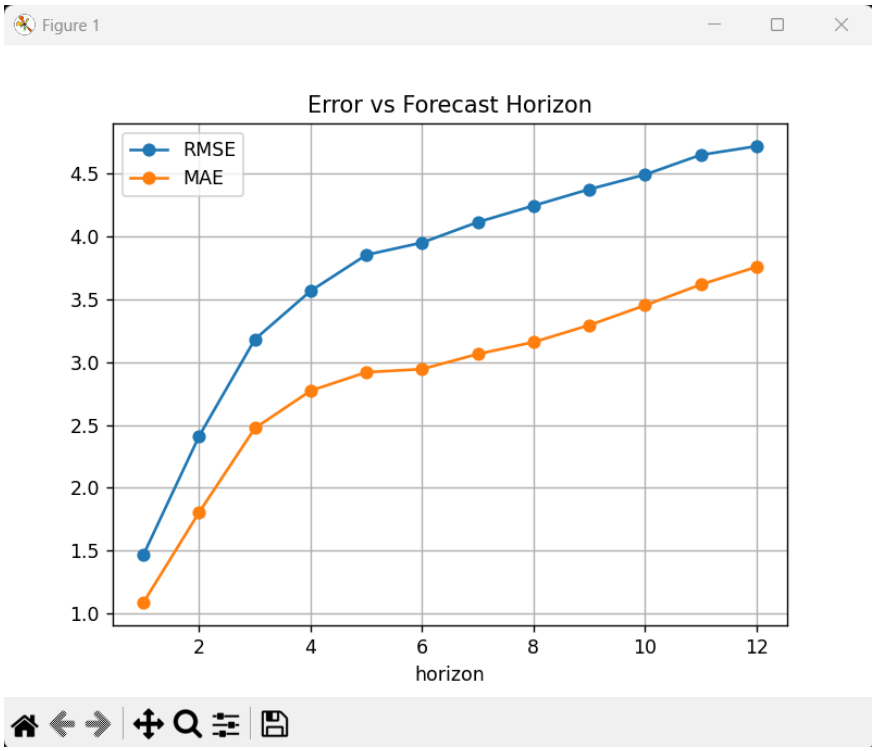

Kiértékelés

A modell teljesítményének értékelése több metrika alapján történt

- MAE – átlagos abszolút hiba
- RMSE – nagy hibák hangsúlyozása
- R^2 – magyarázott variancia
- MAPE / SMAPE – relatív hibák
- MASE – idősort figyelembe vevő baseline összehasonlítás

Eredmények

- a modellek következetesen felülteljesítik a baseline modellt
- a gradient boosting modellek (LightGBM, HistGB) adták a legjobb eredményeket
- az ensemble modell tovább javította a stabilitást

Ensemble modell

A két legjobb modell átlagolásával:

- csökkenthető a variance
- stabilabb predikció

Ez adta a legjobb teljesítményt.

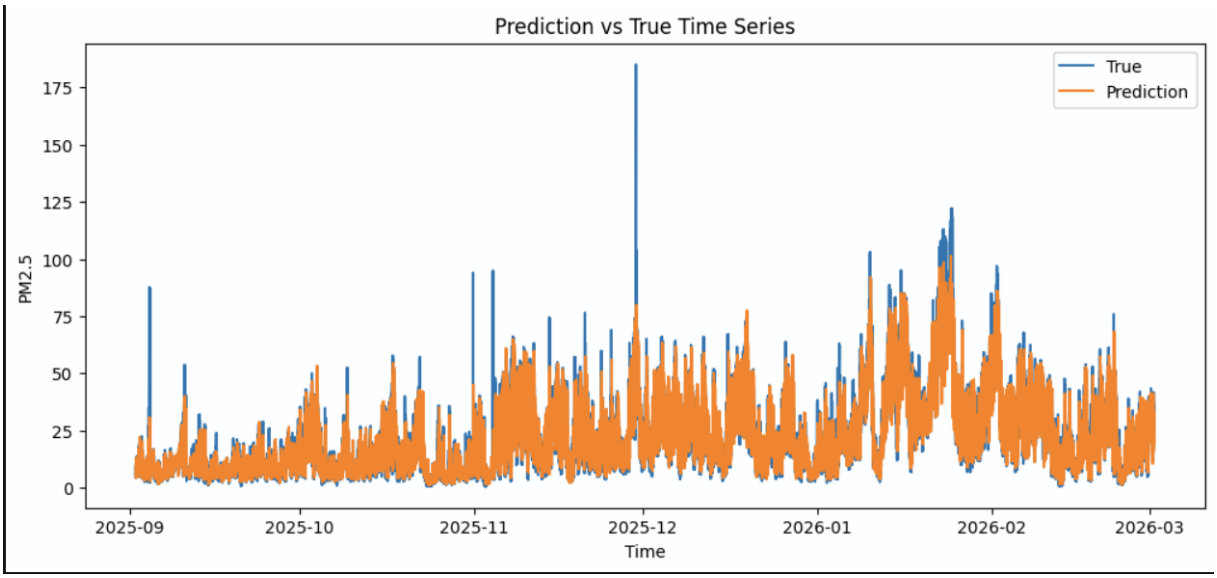

Megfigyelés:

- a modell jól követi az általános trendeket
- extrém értékeknél alulbecslés figyelhető meg13. Modellek összehasonlítása

Interpretáció

Alkalmazott módszerek:

- Permutation importance
- SHAP

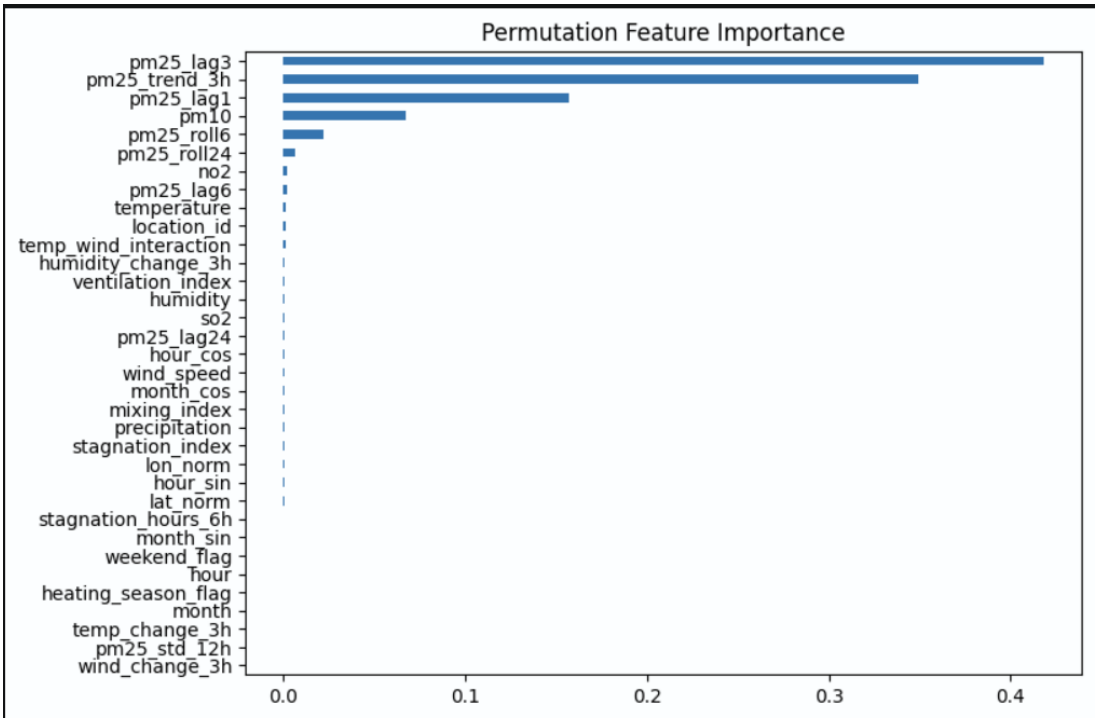

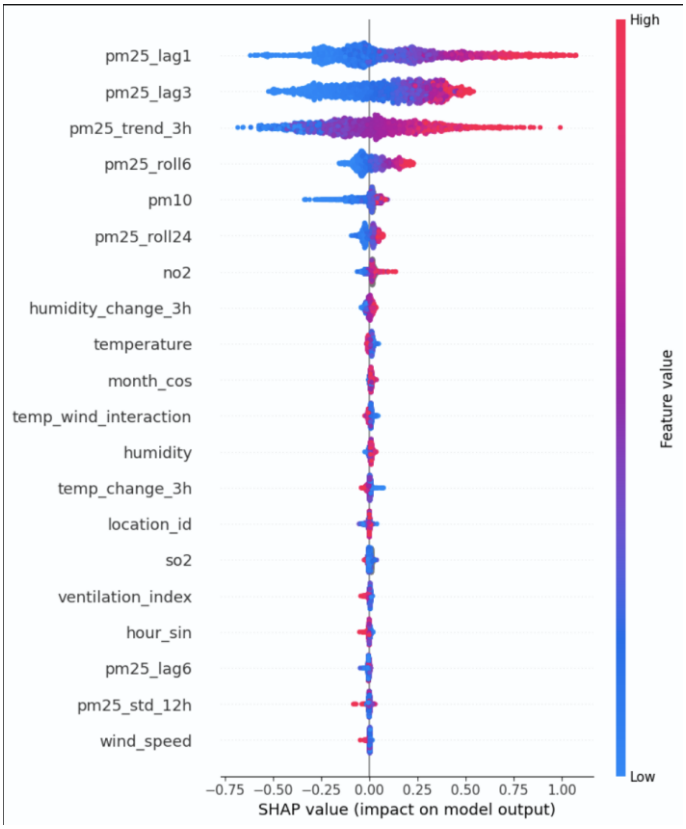

Eredmények:

- a lag feature-ök dominálnak
- időjárási változók kisebb hatásúak

Összegzés

Eredmények és következtetések

- a modell jól teljesít normál tartományban
- magas R^2 és alacsony MAE
- extrém értékeknél alulbecslés figyelhető meg

Limitációk

- Az időjárási adatok nem állomás-specifikusak
- Hiányzó adatok interpolációja torzíthatja a mintázatokat
- Extrém szennyezési események predikciója gyengébb
- A modell erősen támaszkodik a múltbeli PM2.5 értékekre
- Rövid távú (1–12 óra) előrejelzésre optimalizált

Ezek a korlátok a jövőbeli fejlesztések irányát is kijelölik.

Teszt Pipeline

A rendszer egy end-to-end gépi tanulási pipeline, amely az adatgyűjtéstől az API-n keresztüli előrejelzésig terjed.

Fő lépések:

1. adatgyűjtés (API)
2. preprocessing
3. feature engineering
4. modell tanítás
5. kiértékelés
6. előrejelzés

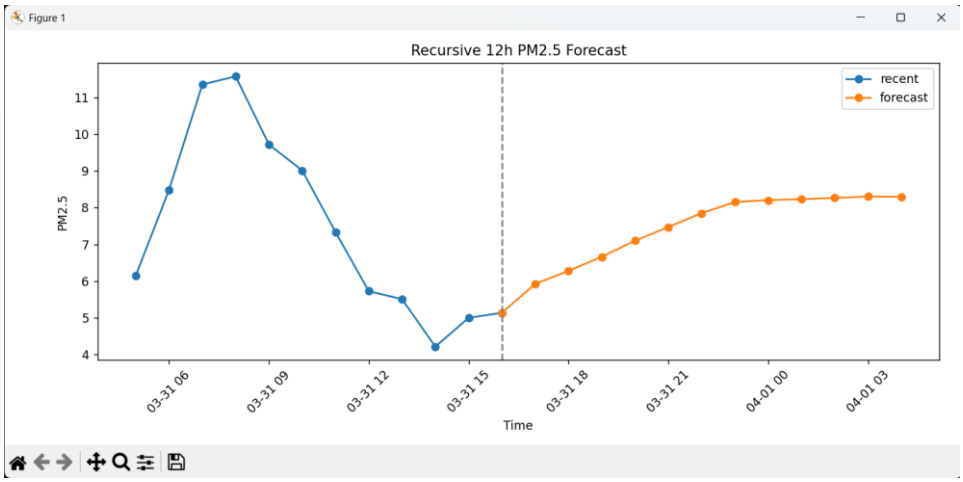

Api

A rendszer FastAPI alapú REST szolgáltatást biztosít.

Fő endpoint:

POST /forecast

Bemenet:

- location
- koordináták
- előrejelzési horizon

Kimenet:

- időbélyeg
- prediktált PM2.5 értékek

http://127.0.0.1:8000/docs

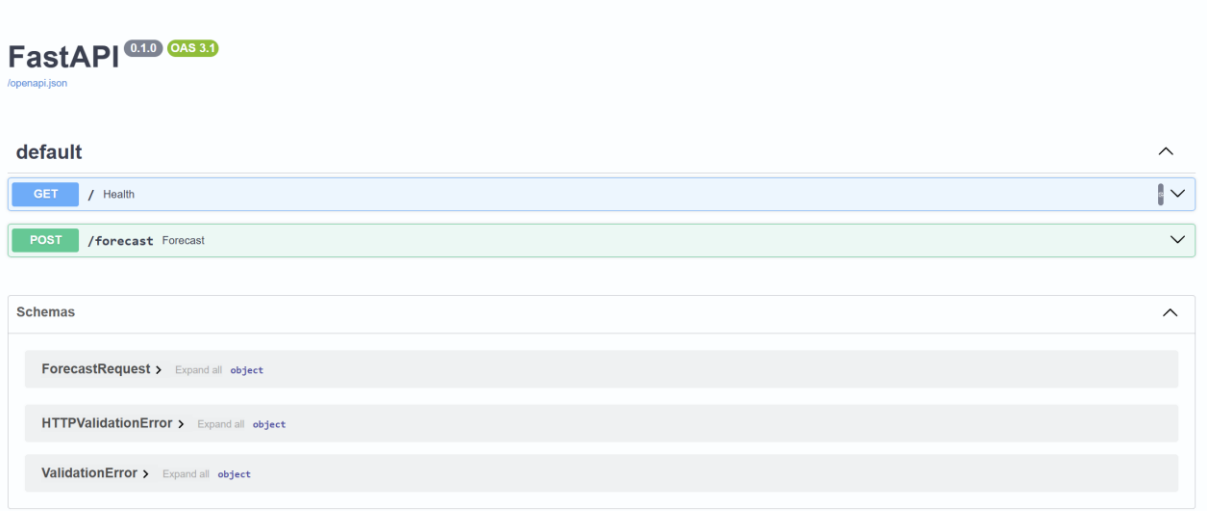

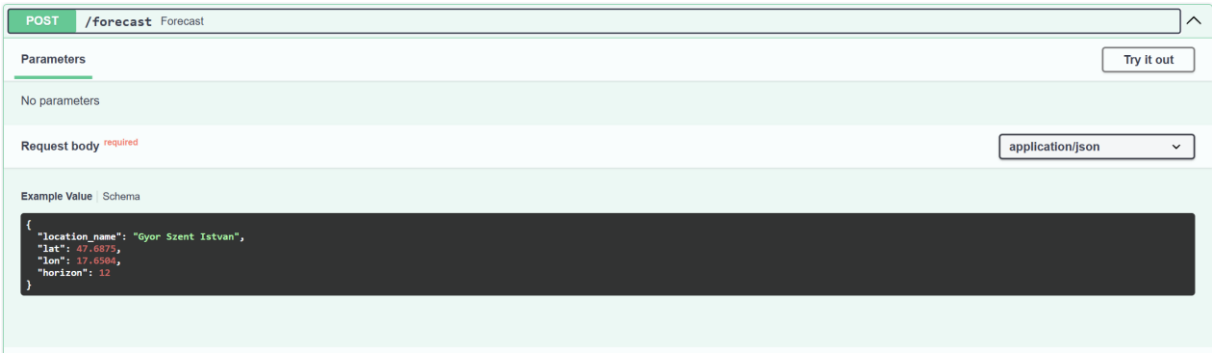

A rendszer:

- validálja a bemeneti adatokat
- betölti a szükséges modelleket és artifactokat
- valós időben generál előrejelzést

Architektúra:

API → Service → Pipeline → Model

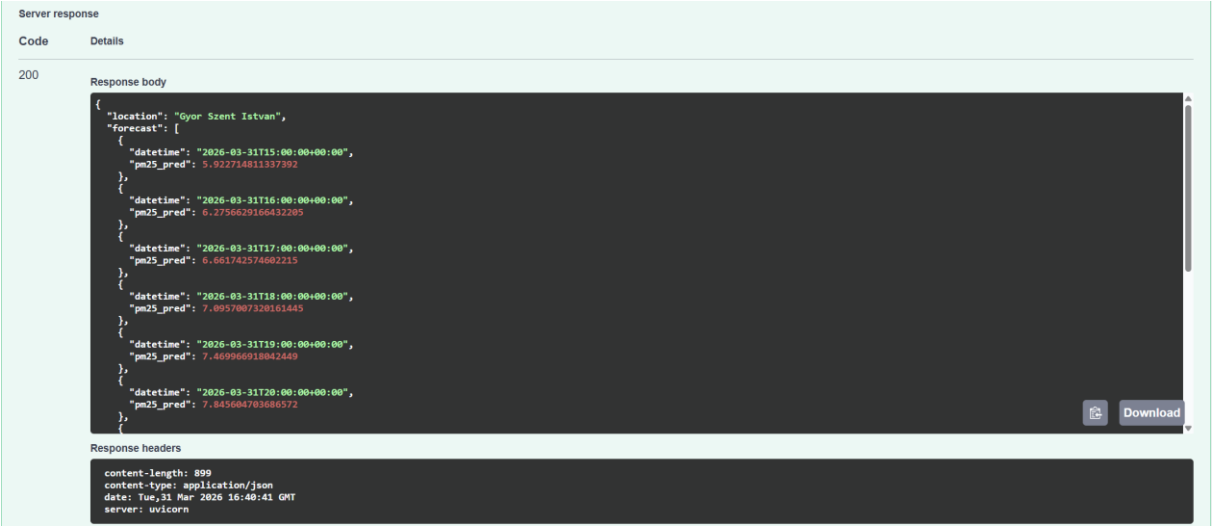

Tovább fejlesztési lehetőségek

- extrém események kezelése
- multi-horizon direct modellek tesztelése (3, 6, 9, 12 órára)
- több meteorológiai adat
- deep learning modellek
- frontend implementáció
- configurációs fájlok
- naplózás a működés pontosabb nyomonkövetéséhez
- adatbázis az adatoknak
- docker implementáció

AI eszközök használata

A projekt során AI eszköz (ChatGPT) került használatra:

- domain és idősoros problémák megértése
- Python szintaxis és könyvtárhasználat támogatása
- gyors prototípus készítés és kísérletezés
- dokumentáció készítése

Fontos:

Az AI eszközök elsősorban a saját ötletek gyors implementálásának támogatására szolgáltak.
A megoldások minden esetben manuálisan ellenőrzésre és módosításra kerültek. Az implementáció saját megértésen és döntéseken alapul.

Felhasznált eszközök

Adatkezelés és feldolgozás

- numpy, pandas

Gépi tanulás

- scikit-learn
- lightgbm
- xgboost

Hiperparaméter optimalizálás

- optuna

Idősoros elemzés

- statsmodels

Modellek mentése és betöltése

- joblib

Model interpretáció

- shap

Adatvizualizáció

- matplotlib
- seaborn

API és backend

- fastapi
- uvicorn

Adatgyűjtés és külső API-k

- requests
- httpx
- openaq

Konfiguráció és környezetkezelés

- python-dotenv

Fogalomtár (rövid magyarázatokkal)

Gépi tanulás / modell

- MAE (Mean Absolute Error)
  Átlagos abszolút hiba; megmutatja, hogy a predikciók átlagosan mennyivel térnek el a valós értékektől.
- RMSE (Root Mean Squared Error)
  Négyzetes hiba gyöke; a nagy hibákat erősebben bünteti.
- R^2 (determinációs együttható)
  Megmutatja, hogy a modell mennyire magyarázza az adatok szórását (1-hez közel jobb).
- MAPE (Mean Absolute Percentage Error)
  Százalékos hiba; relatív eltérést mutat.
- SMAPE (Symmetric MAPE)
  Szimmetrikus százalékos hiba; stabilabb verzió MAPE-re.
- MASE (Mean Absolute Scaled Error)
  Idősoros baseline-hoz viszonyított hiba.
- Baseline modell
  Egyszerű referencia modell (pl. előző érték), amihez a teljesítményt hasonlítjuk.

Idősor és validáció

- Idősor (time series)
  Időben rendezett adatok sorozata.
- Lag (késleltetés)
  Egy változó korábbi értéke (pl. 1 órával ezelőtti PM2.5).
- Rolling statisztika
  Mozgó ablakon számolt érték (pl. utolsó 6 óra átlaga).
- Autokorreláció
  A változó saját múltbeli értékeivel való kapcsolata.
- Train/test split
  Tanító és teszt adatok szétválasztása.
- TimeSeriesSplit
  Idősoros validációs módszer, ahol az időrend megmarad.
- Walk-forward validáció
  Lépésenként előrehaladó validáció, ami valós előrejelzést szimulál.
- Recursive forecasting
  A modell saját előző predikcióit használja bemenetként.
- Horizon
  Előrejelzési időtáv (pl. 12 óra előre).

Adatkezelés

- Feature
  Bemeneti változó, amit a modell használ.
- Feature engineering
  Új, hasznos változók létrehozása az adatokból.
- Target
  Az előrejelzendő változó (itt: PM2.5).
- Preprocessing
  Adatok előkészítése modellezéshez.
- Resampling
  Idősor átalakítása egységes időlépésekre.

- Interpoláció
  Hiányzó értékek becslése köztes adatok alapján.
- NaN (Not a Number)
  Hiányzó vagy érvénytelen adat.

Modellezés és optimalizálás

- Overfitting (túltanulás)
  A modell túl jól illeszkedik a train adatokra, de rosszul generalizál.
- Generalizáció
  A modell képessége új adatokon való jó teljesítésre.
- Hiperparaméter
  Modell tanulás előtt beállított paraméter.
- Optuna
  Automatikus hiperparaméter optimalizáló eszköz.
- Ensemble modell
  Több modell kombinációja a jobb teljesítmény érdekében.
- Variance (szórás)
  A modell érzékenysége az adatok változására.
- Bias (torzítás)
  A modell egyszerűsítéséből adódó hiba.

Dimenziócsökkentés / klaszterezés

- PCA (Principal Component Analysis)
  Dimenziócsökkentő módszer, amely a legfontosabb információkat tartja meg.
- KMeans
  Klaszterező algoritmus, amely csoportokba rendezi az adatokat.

Rendszer és implementáció

- Pipeline
  Feldolgozási lépések egymás utáni láncolata.
- End-to-end rendszer
  Teljes folyamat az adatgyűjtéstől az előrejelzésig.
- Artifact
  Mentett modell vagy paraméter (pl. feature lista).
- Reprodukálhatóság
  Az eredmények újra előállíthatósága.

API és backend

- API (Application Programming Interface)
  Programozási interfész rendszerek közti kommunikációhoz.
- REST API
  HTTP alapú szolgáltatás adatok lekérésére/küldésére.
- Endpoint
  Egy konkrét API hívási pont (pl. /forecast).
- FastAPI
  Python alapú web framework API-k készítéséhez.

Interpretáció

- SHAP (SHapley Additive exPlanations)
  Modellmagyarázó módszer, amely megmutatja a feature-ök hatását.
- Permutation importance
  Feature fontosság mérése változók összekeverésével.

Domain specifikus

- PM2.5
  2.5 mikrométernél kisebb szálló por.
- Stagnation index
  Légköri stagnálás mértéke (rossz levegőcsere).
- Mixing index
  A levegő keveredésének mértéke.
- Ventilation index
  Szennyezőanyagok elszállításának képessége.